

MODUL 2

SPARK MASTER-WORKER

1. Tujuan

- Mahasiswa memahami arsitektur Spark Master.
- Mahasiswa mampu menjalankan Spark di mode standalone (master + worker di satu node).
- Mahasiswa dapat melakukan operasi sederhana pada RDD dan DataFrame menggunakan data lokal.

2. Teori Pendahuluan

- Konsep Big Data & Apache Spark
- Konsep RDD dan DataFrame
- Konsep HDFS vs File Lokal
- Konsep Spark Shell & PySpark

3. Peralatan

- Docker Desktop (Windows, dengan WSL2 Linux container)
- Image Docker: **bde2020/spark-master:3.3.0-hadoop3.3**

4. Hipotesa

Dengan konfigurasi Spark Master standalone, mahasiswa dapat menjalankan proses Spark secara lokal tanpa memerlukan HDFS, dan tetap mampu melakukan transformasi dan aksi pada data besar secara efisien.

5. Tugas Pendahuluan

- Membaca teori Spark
- Memastikan percobaan pada pertemuan 1 (modul 1) sudah running well
- Mahasiswa mempelajari konsep container

6. Rancangan Praktikum

Percobaan ke-1

Mempersiapkan Environment

Langkah-langkah percobaan

- Aktifkan WSL dan jalankan terminal Ubuntu**
Pastikan WSL sudah aktif dan berfungsi. Periksa versi
Jalankan Ubuntu 24.04.1 LTS melalui menu start
Buka powershell sebagai administrator, ketikkan

```
wsl --list --verbose
```

Jika berhasil akan muncul

NAME	STATE	VERSION
* Ubuntu-24.04	Running	2

Pilih distribusi (Ubuntu-24.04) sebagai default

Buka powershell sebagai administrator, ketikkan

```
wsl --setdefault Ubuntu-24.04
```


jika berhasil akan muncul

```
The operation completed successfully.
```

b. Jalankan Docker Desktop

Pastikan Docker terhubung dengan WSL (cek di Settings → Resources → WSL Integration). Caranya

- Jalankan Docker Desktop (cari di start menu)
- Masuk ke Settings (letak di pojok kanan atas)
- Klik menu “Resources”
- Klik tab “WSL Integration”
- Pastikan muncul distro Ubuntu-24.04, dan tercentang (Enable integration with my default WSL distro), klik apply & restart



Uji koneksi dengan perintah

Buka powershell sebagai administrator, ketikkan

```
docker version
```

Jika berhasil akan muncul

```
Client:
Version:      28.5.1
API version:  1.51
Go version:   go1.24.8
Git commit:   e180ab8
Built:        Wed Oct 8 12:19:16 2025
OS/Arch:      windows/amd64
Context:      desktop-linux

Server: Docker Desktop 4.49.0 (208700)
Engine:
Version:      28.5.1
API version:  1.51 (minimum version 1.24)
```

```

Go version:    go1.24.8
Git commit:    f8215cc
Built:         Wed Oct 8 12:17:24 2025
OS/Arch:       linux/amd64
Experimental:   false
containerd:
Version:       1.7.27
GitCommit:     05044ec0a9a75232cad458027ca83437aae3f4da
runc:
Version:       1.2.5
GitCommit:     v1.2.5-0-g59923ef
docker-init:
Version:       0.19.0
GitCommit:     de40ad0
  
```

Ketikkan:

```
docker ps
```

Jika berhasil akan muncul

CONTAINERID	IMAGE	COMMAND	CREATED	STATUS	PORTS	NAMES
-------------	-------	---------	---------	--------	-------	-------

Artinya belum ada container yang sedang berjalan

c. Unduh image Hadoop untuk Docker

Cari Image Hadoop di Docker Hub

Buka powershell sebagai administrator, ketikkan

```
docker search hadoop
```

Akan muncul

NAME	DESCRIPTION	STARS
OFFICIAL		
apache/hadoop	Apache Hadoop convenience builds	122
vulhub/hadoop		0
openeuler/hadoop		0
flokkr/hadoop	Apache Hadoop container with advanced config...	1
danisla/hadoop	Hadoop image built with native libraries	2
harisekhon/hadoop	Apache Hadoop (HDFS + Yarn, tags 2.2 - 2.8)	73
kiwenlau/hadoop	Run Hadoop Cluster in Docker Containers	26
webis/hadoop		0
tailtarget/hadoop	hadoop 2.7.2 image	0
newnius/hadoop	Setup a Hadoop cluster with docker.	1
aristanetworks/hadoop	Hadoop docker image.	0
mtsrus/hadoop	Docker image with Hadoop cluster	5
krdmity/hadoop		0
jack20191124/hadoop	Pseudo-Distributed Hadoop Image	0
kubeguide/hadoop		5
pilchard/hadoop	Hadoop 2.6 (CDH 5.12) base on CentOS with op...	0
adisurya1512/hadoop		0
laithleo/hadoop	Apache Hadoop 3.3.1 on top of YARN	2
cloudsuite/hadoop		3
bmedora/hadoop		0
gelog/hadoop	Use at your own risk.	5
sbloodys/hadoop	This is the definition of the Apache Hadoop ...	0
slpcat/hadoop		0
janle88/hadoop	hadoop镜像	0
colovu/hadoop	Docker image for Hadoop.	1

Gunakan perintah docker pull untuk mengunduh image

Buka powershell sebagai administrator, ketikkan

```
docker pull bde2020/spark-master:3.3.0-hadoop3.3
```

Jika berhasil akan muncul

```
Digest:
sha256:5d2623e337db28c25d4154f20bd81cd234ba7f0bae6b9af87602f4711
9e8acf7
Status: Image is up to date for bde2020/spark-master:3.3.0-hadoop3.3
docker.io/bde2020/spark-master:3.3.0-hadoop3.3
```

Cek Image yang Sudah Diunduh

Buka powershell sebagai administrator, ketikkan

```
docker images
```

Output akan menampilkan semua image yang sudah berhasil diunduh, misalkan

REPOSITORY	TAG	IMAGE ID	CREATED
SIZE			
ubuntu	latest	66460d557b25	6 weeks ago
117MB			
hello-world	latest	56433a6be3fd	3 months ago
20.3kB			
bde2020/spark-worker	3.3.0-hadoop3.3	7cd336bd08d0	3 years ago
970MB			
bde2020/spark-master	3.3.0-hadoop3.3	5d2623e337db	3 years ago
970MB			
bde2020/hadoop-namenode	2.0.0-hadoop3.2.1-java8	51ad9293ec52	5 years ago
2.05GB			
bde2020/hadoop-datanode	2.0.0-hadoop3.2.1-java8	ddf6e9ad55af	5 years ago
2.05GB			

d. Jalankan container Hadoop + Spark Master

Memastikan agar container yang akan dijalankan tidak konflik dengan yang sudah pernah dibuat, maka container bisa dihapus berdasarkan nama container atau hapus semua (silahkan pilih sesuai kebutuhan)

Untuk hapus semua container yang tidak aktif, Buka powershell sebagai administrator, ketikkan

```
docker container prune
```

Untuk hapus semua container termasuk yang aktif

```
docker rm -f $(docker ps -aq)
```

Untuk hapus container yang diinginkan, misal id containernya Adalah:
c1a0709b442b4c7e53f6bae18665228aa0cc32f0bcd7699d6e72017546f1d72d

```
docker rm c1a0709b442b4c7e53f6bae18665228aa0cc32f0bcd7699d6e72017546f1d72d
```

cara cek semua container yang aktif dan yang stop

```
docker ps -a
```

Jika outputnya

CONTAINER ID	IMAGE	COMMAND	CREATED	STATUS	PORTS	NAMES
--------------	-------	---------	---------	--------	-------	-------

Artinya tidak ada container yang aktif

Percobaan ke-2

Menjalankan Spark Master dan Spark Worker

Langkah-langkah percobaan

a. Jalankan Spark Master (sekalius Hadoop Namenode)

Buka powershell sebagai administrator, ketikkan

```
docker run -d --name spark-master -p 8080:8080 -p 7077:7077  
bde2020/spark-master:3.3.0-hadoop3.3
```


Outputnya misalkan

```
e17abdd8b9e13c6a6dbaa8445585478f6c988381ddb50109d260  
84434861846c
```

Cek di web UI, ketikkan di browser

```
localhost:8080
```

Jika berhasil, maka di browser akan tampil



b. Jalankan Worker 1

Buka powershell sebagai administrator, ketikkan

```
docker run -d --name spark-worker --link spark-  
master:spark-master -p 8081:8081 bde2020/spark-  
worker:3.3.0-hadoop3.3
```


Outputnya misalkan

```
288f55881d99f45b7b6385cdc9a8b8a4cc9086ef9737cacb7cf93c5fec49703b
```

Cek di web UI, ketikkan di browser

```
localhost:8081
```

Jika berhasil, maka di browser akan tampil



Percobaan ke-3

Menjalankan Job Spark

Langkah-langkah percobaan

a. menjalankan spark-shell Cara ke-1

Buka powershell sebagai administrator, ketikkan

```
docker exec -it spark-master bash
```

Akan muncul prompt baru

```
bash-5.0#
```

Selanjutkan jalankan diprompt tersebut

```
/spark/bin/spark-shell
```

Jika berhasil maka akan tampil

Welcome to



version 3.3.0

Untuk keluar dari spark-shell

```
:quit
```

b. menjalankan spark-shell Cara ke-2

Buka powershell sebagai administrator, ketikkan

```
docker exec -it spark-master bash
```

Akan muncul prompt baru

```
bash-5.0#
```

Selanjutnya jalankan diprompt tersebut

```
pyspark
```

Jika muncul error command not found, ketikkan

```
find / -name pyspark
```

Outputnya:

```
/spark/bin/pyspark  
/spark/python/pyspark  
/spark/python/pyspark/python/pyspark
```

Pilih (ketikkan)

```
/spark/bin/pyspark
```

Jika berhasil maka akan tampil



Bedanya Adalah cara yang kedua ini, promptnya

```
>>>
```

Untuk keluar dari spark-shell

```
:quit
```

Percobaan ke-3


Menjalankan script Python (PySpark)

Langkah-langkah percobaan

a. Screenshoot Web UI spark master dan spark worker


Tujuannya Adalah untuk mengetahui perubahan setelah script python (PySpark) di running

Untuk SS Spark Master berikut perhatikan, tertulis Alive Worker: 1

A screenshot of the Spark Master Web UI in a browser. The title is "Spark Master at spark://e17abdd8b9e1:7077". It shows the URL, 1 alive worker, and various resource usage statistics. Below the statistics, there are three expandable sections: "Workers (1)", "Running Applications (0)", and "Completed Applications (0)". The "Workers (1)" section is expanded, showing a table with one worker's details.

Worker Id	Address	State	Cores	Memory	Resources
worker-20251113030609-172.17.0.3-43191	172.17.0.3:43191	ALIVE	8 (0 Used)	6.7 GiB (0.0 B Used)	

Untuk SS Spark Master berikut perhatikan, tertulis Alive Worker: 1



b. Menjalankan kode python

Jalankan contoh kode:

spypark

```
import random

# Inisialisasi list untuk menyimpan data
data_penghasilan = []

# Membuat 10 dataset random
for i in range(10):
    gaji_pokok = random.randint(3000000, 10000000) # Gaji pokok antara 3 juta sampai 10 juta
    lembur = random.randint(0, 2000000) # Lembur antara 0 sampai 2 juta
    total_penghasilan = gaji_pokok + lembur
    data_penghasilan.append({
        "Gaji Pokok": gaji_pokok,
        "Lembur": lembur,
        "Total Penghasilan": total_penghasilan
    })

# Tampilkan dataset
print("Dataset Penghasilan:")
for i, data in enumerate(data_penghasilan, start=1):
    print(f"{i}. Gaji Pokok: Rp {data['Gaji Pokok']:,}, Lembur: Rp {data['Lembur']:,}, Total: Rp {data['Total Penghasilan']:,}")

# Hitung rata-rata penghasilan
```

```
total_semua = sum(item['Total Penghasilan'] for item
in data_penghasilan)
rata_rata_penghasilan = total_semua /
len(data_penghasilan)

print(f"\nRata-rata Total Penghasilan: Rp
{rata_rata_penghasilan:,.0f}")
```

outputnya Adalah

```
>>> import random
>>>
>>> # Inisialisasi list untuk menyimpan data
>>> data_penghasilan = []
>>>
>>> # Membuat 10 dataset random
>>> for i in range(10):
...     gaji_pokok = random.randint(3000000, 10000000) # Gaji pokok antara 3
juta sampai 10 juta
...     lembur = random.randint(0, 2000000) # Lembur antara 0 sampai 2 juta
...     total_penghasilan = gaji_pokok + lembur
...     data_penghasilan.append({
...         "Gaji Pokok": gaji_pokok,
...         "Lembur": lembur,
...         "Total Penghasilan": total_penghasilan
...     })
...
>>> # Tampilkan dataset
>>> print("Dataset Penghasilan:")
Dataset Penghasilan:
>>> for i, data in enumerate(data_penghasilan, start=1):
...     print(f"{i}. Gaji Pokok: Rp {data['Gaji Pokok']:,}, Lembur: Rp
{data['Lembur']:,}, Total: Rp {data['Total Penghasilan']:,}")
...
1. Gaji Pokok: Rp 9,270,808, Lembur: Rp 267,220, Total: Rp 9,538,028
2. Gaji Pokok: Rp 6,752,472, Lembur: Rp 441,316, Total: Rp 7,193,788
3. Gaji Pokok: Rp 3,085,817, Lembur: Rp 1,082,440, Total: Rp 4,168,257
4. Gaji Pokok: Rp 8,398,156, Lembur: Rp 1,617,122, Total: Rp 10,015,278
5. Gaji Pokok: Rp 3,501,470, Lembur: Rp 409,264, Total: Rp 3,910,734
6. Gaji Pokok: Rp 6,358,751, Lembur: Rp 1,954,854, Total: Rp 8,313,605
7. Gaji Pokok: Rp 3,287,036, Lembur: Rp 923,805, Total: Rp 4,210,841
8. Gaji Pokok: Rp 7,923,815, Lembur: Rp 1,601,859, Total: Rp 9,525,674
9. Gaji Pokok: Rp 6,468,381, Lembur: Rp 729,541, Total: Rp 7,197,922
10. Gaji Pokok: Rp 5,354,661, Lembur: Rp 246,028, Total: Rp 5,600,689
>>> # Hitung rata-rata penghasilan
>>> total_semua = sum(item['Total Penghasilan'] for item in data_penghasilan)
>>> rata_rata_penghasilan = total_semua / len(data_penghasilan)
>>>
>>> print(f"\nRata-rata Total Penghasilan: Rp {rata_rata_penghasilan:,.0f}")

Rata-rata Total Penghasilan: Rp 6,967,482
>>>
```

Jika output sudah sesuai, artinya percobaan 3 sudah berhasil

Harap diperhatikan, apabila Percobaan pada modul 2 belum tuntas (belum berhasil), maka praktikan tidak bisa melanjutkan ke pertemuan berikutnya (modul 3).

7. Laporan Akhir

Laporan akhir berisi aktifitas hasil praktikum, meliputi:

- Teori Pendahuluan
- Tugas Pendahuluan

- c. Hipotesa
- d. Hasil pengamatan praktikum
- e. Analisa antara Hipotesa dan hasil praktikum. Apabila hipotesa sesuai dengan hasil praktikum, tunjukkan poin-poin yang sesuai. Apabila hipotesa tidak sesuai dengan hasil praktikum, tunjukkan alasan penyebabnya. Dapat ditambahkan dengan teori-teori tambahan sebagai pendukung.

